



UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO



FACULTAD DE CIENCIAS

Almacenes y Minería de Datos

Práctica 4

*Medidas de Heterogeneidad y
Concentración. Visualización de Datos. Índices de
Gini y Entropía, aplicados al Análisis Exploratorio
de la Violencia contra las Mujeres*

Profesora:
Jessica Santizo Galicia

Ayudante:
Diego Antonio Villalba González

Ayudante de Laboratorio:
Emma Alicia Jiménez Sánchez

Integrantes de equipo:
Flores Morán Julieta Melina
García Landa Brenda Yareli
Jiménez Rivera Emiliano Kaleb
Zarco Romero José Antonio

Índice	
Índice	2
Introducción	3
Datos y herramientas	3
Medidas de Localización	4
Medidas de Localización	4
Medidas de Variabilidad	4
Medidas de Heterogeneidad	5
Índice de Variación Cualitativa (IQV)	5
Índice de Gini-Simpson	5
Entropía de Shannon	5
Comparación de las medidas de heterogeneidad	6
Interpretación de los resultados	8
Medidas de Concentración	9
Distribución de casos por entidad federativa	9
Curva de Lorenz	10
Coeficiente de Gini	10
Factor de expansión y decisiones de ponderación	11
Comparación entre Gini y Entropía	11
Aplicación sobre una misma variable	11
Comparación de resultados	12
Interpretación conceptual	13
Tabla de Resultados	14
Cuestionario	16
Interpretación de la curva de Lorenz y Gini	16
Limitaciones y mejoras	16
Uso de las medidas en decisiones posteriores	17
Consideraciones éticas y comunicación	17
Referencias	18

Introducción

La Encuesta Nacional sobre la Dinámica de las Relaciones en los Hogares (ENDIREH) 2021, levantada por el Instituto Nacional de Estadística y Geografía (INEGI), recopila información sobre las experiencias de violencia que han vivido las mujeres de 15 años y más en distintos ámbitos, como pareja, familiar, escolar, laboral y comunitario. Los datos representan experiencias reales reportadas por las encuestadas.

En la Práctica 3 se realizó el preprocesamiento y análisis exploratorio inicial de este conjunto de datos, obteniendo una base limpia que sirve como punto de partida para la presente práctica.

El objetivo es describir cuantitativamente el conjunto de datos ENDIREH 2021 mediante medidas de localización, variabilidad, heterogeneidad y concentración, incluyendo el coeficiente de Gini y la entropía de Shannon, y comunicar los resultados mediante visualizaciones adecuadas. En concreto, se analizaron: (i) medidas de localización y variabilidad, como la media y mediana ponderadas, el coeficiente de variación y el rango intercuartílico; (ii) medidas de heterogeneidad sobre variables cualitativas, mediante el IQV, el índice de Gini-Simpson y la entropía de Shannon; (iii) medidas de concentración de los casos por entidad federativa, utilizando la curva de Lorenz y el coeficiente de Gini; y (iv) una síntesis que compara Gini y entropía sobre una misma variable categórica.

Más allá del cálculo de estos índices, se busca reflexionar sobre lo que estas medidas permiten revelar y sobre lo que pueden ocultar acerca de la violencia contra las mujeres, considerando sus limitaciones y la importancia de comunicar los resultados de manera responsable.

Datos y herramientas

Se trabajó con el archivo `endireh_2021_limpio.csv`, ubicado en `data/data-processed/` y generado en la Práctica 3 (sin duplicados, con tipos correctos y sin valores faltantes). Las rutas de los archivos se definen en `config/rutas.py`.

Las herramientas utilizadas fueron:

- **polars** (framework de datos seleccionado en la Práctica 3) para carga, filtrado y agregaciones.
- **NumPy** para los índices propios (Gini, Lorenz, entropía) y los percentiles/medidas ponderadas
- **Funciones propias** en un módulo reutilizable del proyecto para el coeficiente de Gini, la curva de Lorenz, la entropía de Shannon, el índice de Gini-Simpson y el IQV,

ya que ningún framework de propósito general las implementa de fábrica. En <https://github.com/AyMD-2027-1/proyecto-endireh-violencia/blob/practica-4/src/eda/indices.py>

- **Matplotlib / Seaborn** para histogramas, boxplots, gráficas de barras y la curva de Lorenz.
- **Jupyter Notebook / Google Colab** para el desarrollo narrativo del análisis (un notebook por tipo de medida en la carpeta notebooks/).
- **Git** para el control de versiones dentro del repositorio de la Práctica 3: <https://github.com/AyMD-2027-1/proyecto-endireh-violencia/tree/practica-4>

Resumen Ejecutivo

En esta práctica se describió la ENDIREH 2021 (105,753 mujeres tras la limpieza, ponderadas por factor de expansión) con medidas de heterogeneidad y concentración. Los casos de violencia de pareja reportada (17.8 % de las encuestadas) se distribuyen entre las entidades con un Gini de 0.418, una concentración moderada muy parecida a la de la población de mujeres (0.406), por lo que refleja el tamaño de cada entidad y no mayor violencia. El estado civil es una variable diversa (IQV 0.911, $H = 2.25$ bits de 2.585), mientras que ahorros y apoyo del gobierno están dominadas por una categoría (IQV 0.39 y 0.45). Gini y entropía coinciden en que las mujeres con violencia de pareja se reparten de forma más pareja entre estados civiles que la población general (H_{norm} 0.952 vs. 0.869; G_{norm} 0.277 vs. 0.446), con separadas y divorciadas sobrerrepresentadas. Hay que tener en cuenta que los resultados describen violencia reportada y no permiten inferir riesgo ni causa.

Medidas de Localización

Las medidas de localización de edad_primer_union, num_hijos e ingreso_pareja (media, mediana, moda, cuantiles y media ponderada por el factor de expansión), sin preprocesamiento y con los datos procesados, ya se reportaron e interpretaron en la Práctica 3, por lo que no se repiten aquí. En esta práctica solo se agrega la mediana ponderada que pide la tabla de resultados; sus valores se incluyen en la Tabla de Resultados.

Medidas de Variabilidad

El rango, la varianza, la desviación estándar, el coeficiente de variación (CV) y el rango intercuartílico (IQR) de las mismas variables, sin preprocesamiento y con los datos procesados, ya se reportaron e interpretaron en la Práctica 3. Los valores de CV e IQR que se usan en esta práctica se incluyen en la Tabla de Resultados.

Medidas de Heterogeneidad

Las medidas de heterogeneidad permiten describir qué tan repartidas se encuentran las observaciones entre las categorías de una variable cualitativa. En esta práctica se utilizan tres índices: IQV, Gini-Simpson y entropía de Shannon. Los tres alcanzan un valor mínimo cuando una sola categoría concentra todas las observaciones y aumentan conforme la distribución se hace más diversa y equilibrada.

Se analizaron `nom_entidad`, `estado_civil_desc`, `sufrio_violencia_pareja`, `apoyo_gobierno_desc` y `tiene_ahorros_desc`, variables con distinto número de categorías y grado de diversidad. Los valores se reportan ponderados por `factor_expansion`, porque el objetivo es describir a la población de mujeres de 15 años y más y no solo a la muestra.

Índice de Variación Cualitativa (IQV)

El IQV normaliza el índice de Gini-Simpson para que tome valores entre 0 y 1, lo que permite comparar variables con distinto número de categorías:

$$IQV = k \cdot (1 - \sum p_i^2) / (k - 1)$$

Para este índice se eligió `estado_civil_desc`, con seis categorías. Ponderada por el factor de expansión, la distribución es: casada 35.0 %, soltera 26.1 %, unión libre 18.4 %, viuda 8.9 %, separada 8.8 % y divorciada 2.7 %. El IQV fue de 0.911 (0.895 sin ponderar), muy cercano a 1, lo que indica alta heterogeneidad: ninguna categoría concentra a la mayoría de las mujeres. En contraste, `tiene_ahorros_desc` tiene un IQV de 0.391, porque cerca de 89 % de las mujeres pertenece a una sola categoría.

Índice de Gini-Simpson

Es la probabilidad de que dos observaciones elegidas al azar pertenezcan a categorías distintas:

$$GS = 1 - \sum p_i^2$$

Para `estado_civil_desc`, el Gini-Simpson fue de 0.759 (0.746 sin ponderar), frente a un máximo de $1 - 1/k = 0.833$. Es decir, si se eligen dos mujeres al azar, la probabilidad de que tengan estados civiles distintos es de aproximadamente 76 %. Como referencia, `tiene_ahorros_desc` tiene 0.196 sobre un máximo de 0.5, lo que indica poca diversidad.

Entropía de Shannon

Mide la incertidumbre (en bits) sobre la categoría de una observación elegida al azar. Su valor máximo es $\log_2(k)$, alcanzado cuando todas las categorías son equiprobables:

$$H = - \sum p_i \cdot \log_2(p_i), \quad 0 \leq H \leq \log_2(k)$$

Para estado_civil_desc, la entropía fue de 2.247 bits (2.218 sin ponderar) sobre un máximo de $\log_2(6) = 2.585$, es decir, una entropía normalizada de 0.869: una distribución diversa, pero no uniforme, pues divorciada (2.7 %) pesa mucho menos que casada (35.0 %). tiene_ahorros_desc tiene $H = 0.500$ sobre un máximo de 1, una variable mucho más predecible. Ponderar o no cambia poco los valores y no altera la conclusión.

Comparación de las medidas de heterogeneidad

```
--- Heterogeneidad (crudo): proporciones simples ---
shape: (10, 9)
```

variable	n	k	gini_simpson	gs_max(1-1/k)	iqv	shannon_H	H_max(log2 k)	H/H_max
---	---	---	---	---	---	---	---	---
str	i64	i64	f64	f64	f64	f64	f64	f64
nom_entidad	110127	32	0.968693	0.96875	0.999941	4.998668	5.0	0.999734
nivel_escolaridad	110127	6	0.59883	0.833333	0.718596	1.810903	2.584963	0.700553
estado_civil_desc	110127	6	0.739494	0.833333	0.887393	2.195758	2.584963	0.849435
estrato_socioeconomico	110127	4	0.644506	0.75	0.859341	1.716854	2.0	0.858427
pareja_trabaja_desc	110127	2	0.493897	0.5	0.987794	0.991177	1.0	0.991177
dinero_propio_desc	110127	2	0.498887	0.5	0.997773	0.998393	1.0	0.998393
apoyo_gobierno_desc	110127	2	0.237603	0.5	0.475205	0.578412	1.0	0.578412
tiene_ahorros_desc	110127	2	0.193331	0.5	0.386661	0.495133	1.0	0.495133
propietaria_vivienda_desc	110127	2	0.447005	0.5	0.89401	0.922133	1.0	0.922133
sufrio_violencia_pareja	110127	2	0.289149	0.5	0.578297	0.669701	1.0	0.669701

```
--- Heterogeneidad (crudo): ponderada con factor_expansion ---
shape: (10, 9)
```

variable	n	k	gini_simpson	gs_max(1-1/k)	iqv	shannon_H	H_max(log2 k)	H/H_max
---	---	---	---	---	---	---	---	---
str	i64	i64	f64	f64	f64	f64	f64	f64
nom_entidad	110127	32	0.946322	0.96875	0.976848	4.597004	5.0	0.919401
nivel_escolaridad	110127	6	0.665619	0.833333	0.798743	1.982537	2.584963	0.76695
estado_civil_desc	110127	6	0.756033	0.833333	0.907239	2.235541	2.584963	0.864825
estrato_socioeconomico	110127	4	0.654669	0.75	0.872891	1.744303	2.0	0.872151
pareja_trabaja_desc	110127	2	0.493648	0.5	0.987295	0.990816	1.0	0.990816
dinero_propio_desc	110127	2	0.499101	0.5	0.998202	0.998702	1.0	0.998702
apoyo_gobierno_desc	110127	2	0.223299	0.5	0.446599	0.552053	1.0	0.552053
tiene_ahorros_desc	110127	2	0.191773	0.5	0.383546	0.492106	1.0	0.492106
propietaria_vivienda_desc	110127	2	0.444062	0.5	0.888124	0.917722	1.0	0.917722
sufrio_violencia_pareja	110127	2	0.28777	0.5	0.57554	0.667329	1.0	0.667329

Resultados Medidas de Heterogeneidad sin Preprocesamiento – Referencia

```
--- Heterogeneidad (procesado): proporciones simples ---
shape: (11, 9)
```



variable	n	k	gini_simpson	gs_max(1-1/k)	iqv	shannon_H	H_max(log2 k)	H/H_max
---	---	---	---	---	---	---	---	---
str	i64	i64	f64	f64	f64	f64	f64	f64
nom_entidad	105753	32	0.968702	0.96875	0.999951	4.998898	5.0	0.99978
nivel_escolaridad	105753	6	0.612956	0.833333	0.735547	1.848789	2.584963	0.715209
estado_civil_desc	105753	6	0.745556	0.833333	0.894667	2.21796	2.584963	0.858024
estrato_socioeconomico	105753	4	0.642406	0.75	0.856541	1.713612	2.0	0.856806
pareja_trabaja_desc	105753	2	0.497114	0.5	0.994227	0.995832	1.0	0.995832
dinero_propio_desc	105753	2	0.497616	0.5	0.995231	0.996557	1.0	0.996557
apoyo_gobierno_desc	105753	2	0.240467	0.5	0.480935	0.583634	1.0	0.583634
tiene_ahorros_desc	105753	2	0.199127	0.5	0.398254	0.506333	1.0	0.506333
propietaria_vivienda_desc	105753	2	0.450599	0.5	0.901199	0.927507	1.0	0.927507
sufrio_violencia_pareja	105753	2	0.29721	0.5	0.59442	0.683508	1.0	0.683508
nunca_tuvo_union	105753	2	0.347369	0.5	0.694739	0.766952	1.0	0.766952


```
--- Heterogeneidad (procesado): ponderada con factor_expansion ---
shape: (11, 9)
```

variable	n	k	gini_simpson	gs_max(1-1/k)	iqv	shannon_H	H_max(log2 k)	H/H_max
---	---	---	---	---	---	---	---	---
str	i64	i64	f64	f64	f64	f64	f64	f64
nom_entidad	105753	32	0.945809	0.96875	0.976319	4.590937	5.0	0.918187
nivel_escolaridad	105753	6	0.673891	0.833333	0.808669	2.005634	2.584963	0.775885
estado_civil_desc	105753	6	0.758777	0.833333	0.910533	2.24682	2.584963	0.869189
estrato_socioeconomico	105753	4	0.652986	0.75	0.870649	1.741453	2.0	0.870727
pareja_trabaja_desc	105753	2	0.496014	0.5	0.992028	0.994242	1.0	0.994242
dinero_propio_desc	105753	2	0.498294	0.5	0.996588	0.997537	1.0	0.997537
apoyo_gobierno_desc	105753	2	0.225121	0.5	0.450242	0.555438	1.0	0.555438
tiene_ahorros_desc	105753	2	0.195616	0.5	0.391233	0.499561	1.0	0.499561
propietaria_vivienda_desc	105753	2	0.446755	0.5	0.893509	0.921758	1.0	0.921758
sufrio_violencia_pareja	105753	2	0.293226	0.5	0.586452	0.6767	1.0	0.6767
nunca_tuvo_union	105753	2	0.349341	0.5	0.698682	0.770151	1.0	0.770151

Resultados Medidas de Heterogeneidad con Datos Procesados

...





Interpretación de los resultados

Crudo vs. procesado. La limpieza cambia poco los IQV (por ejemplo, tiene_ahorros_desc pasa de 0.387 a 0.398) y el orden de las variables no cambia, por lo que no distorsionó las distribuciones. Las más heterogéneas son nom_entidad, dinero_propio_desc y pareja_trabaja_desc; las menos, tiene_ahorros_desc y apoyo_gobierno_desc, dominadas por una categoría.

Efecto del factor de expansión. Ponderar afecta sobre todo a nom_entidad, cuyo IQV baja de casi 1.00 a 0.976: sin ponderar las 32 entidades aparecen casi parejas porque la muestra se reparte de forma similar, y al ponderar se refleja que la población de mujeres no es igual en cada entidad. nivel_escolaridad sube de 0.736 a 0.809; en el resto el cambio es pequeño.

IQV vs. entropía normalizada. Ordenan las variables casi igual. La entropía normalizada es mayor que el IQV en variables dominadas por una categoría (tiene_ahorros_desc: 0.50 vs. 0.39) y menor en variables con varias categorías de distinto tamaño (estado_civil_desc: 0.869 vs. 0.911).


Medidas de Concentración

Para estudiar la concentración territorial de los casos de violencia reportados se analiza la distribución de los casos entre las entidades federativas. En este contexto, la curva de Lorenz permite visualizar qué proporción acumulada de casos corresponde a una proporción acumulada de entidades ordenadas por el número de casos, mientras que el coeficiente de Gini resume numéricamente el grado de desigualdad de esa distribución.


Distribución de casos por entidad federativa

En números absolutos, el Estado de México (1.33 millones de mujeres que reportaron violencia de pareja, 15.2 % de los casos), Ciudad de México (8.0 %), Veracruz (7.1 %) y Jalisco (7.1 %) acumulan más casos; Baja California Sur (0.5 %), Campeche y Colima (0.6 % cada una), menos. Este orden sigue de cerca el tamaño de la población de cada entidad: el Estado de México, por ejemplo, también concentra el 14.0 % de las mujeres del país.

Estas diferencias no deben leerse como entidades con más o menos violencia: la ENDIREH mide violencia reportada, que depende de la disposición a reconocerla y declararla, del contexto cultural y lingüístico y del error muestral, que no se estimó en esta práctica.



Curva de Lorenz



La curva de los casos ponderados se aleja claramente de la diagonal: la mitad de las entidades con menos casos acumula solo el 23 % de ellos, mientras que las 5 con más casos concentran el 42.7 %. Esa curva casi se superpone con la de la población de mujeres: los casos se concentran donde vive más gente.

La curva de Lorenz grafica la proporción acumulada de entidades (ordenadas de menor a mayor número de casos) contra la proporción acumulada de casos. La diagonal de 45° representa la igualdad perfecta; mientras más se aleja la curva de ella, mayor es la concentración.

Coeficiente de Gini

Casos ponderados: $G = 0.418$, una concentración moderada (con $n = 32$ el máximo alcanzable es $(n - 1)/n = 0.969$). Población de mujeres: $G = 0.406$, prácticamente el mismo valor, así que casi toda la concentración de los casos se explica por el tamaño de las entidades. Casos sin ponderar: $G = 0.096$, que solo refleja que cada entidad tiene una muestra de tamaño parecido.

Factor de expansión y decisiones de ponderación

Los casos de cada entidad se calculan como la suma de `factor_expansion` × `sufrio_violencia_pareja`, y la población como la suma del factor de expansión. Sin ponderar, cada entidad aporta ~3,300 entrevistas por diseño y el conteo de casos en la muestra ($G = 0.096$) daría la impresión falsa de un reparto homogéneo. El objetivo es describir a la población de mujeres, no a la muestra. Además, se compara con la curva de la población para no confundir la concentración de los casos con el tamaño de cada entidad.

Comparación entre Gini y Entropía

La entropía de Shannon mide qué tan repartidas están las mujeres entre los estados civiles. Si imaginamos seis casillas, una por estado civil, la entropía es máxima cuando todas tienen el mismo tamaño y vale cero cuando una sola contiene a todas las mujeres. El coeficiente de Gini, aplicado a las frecuencias de esas casillas, mide qué tan desiguales son sus tamaños: vale cero cuando todas son iguales y llega a su máximo cuando una sola concentra todo. Cuando una categoría domina, la entropía baja y el Gini sube; cuando las categorías están parejas, la entropía sube y el Gini baja.

Cada índice tiene su propia escala. Con seis categorías, la entropía va de 0 a $\log_2(6) = 2.585$ bits y el Gini va de 0 a $(k - 1)/k = 0.833$. Al dividir cada índice entre su máximo se obtienen H_{norm} y G_{norm} , que van de 0 a 1 y permiten leer qué porcentaje de su máximo alcanza cada uno. Como los dos apuntan en sentidos opuestos ($H_{\text{norm}} = 1$ y $G_{\text{norm}} = 0$ corresponden a un reparto perfecto), la comparación se hace con la distancia a un reparto perfecto: $1 - H_{\text{norm}}$ para la entropía y G_{norm} para el Gini. Entre más pequeña es esa distancia, más parejo es el reparto.

Aplicación sobre una misma variable

Elegimos el estado civil (`estado_civil_desc`), con 6 categorías: Casada, Divorciada, Separada, Soltera, Unión libre y Viuda. Calculamos los índices para todas las mujeres y para las que reportaron violencia de pareja, con y sin factor de expansión. El cálculo ponderado describe a la población de mujeres y el cálculo sin ponderar describe a las encuestadas.


Escenario	H (bits)	H_norm	G	G_norm
Todas - ponderado	2.247	0.869	0.372	0.446
Todas - sin ponderar	2.218	0.858	0.388	0.465
Con violencia - ponderado	2.460	0.952	0.231	0.277
Con violencia - sin ponderar	2.441	0.944	0.248	0.298

Tabla 1. Entropía de Shannon (H) y Gini (G) sobre las frecuencias de estado civil. $k = 6$. $H_{\text{norm}} = H / \log_2(k)$; $G_{\text{norm}} = G \cdot k / (k - 1)$.

Entre las mujeres con violencia de pareja, separada pasa de 8.8% a 22.4% y divorciada de 2.7% a 6.8%, mientras que casada baja de 35.0% a 27.6% y soltera de 26.1% a 16.6%. Las categorías pequeñas crecen y las grandes se reducen, por lo que la distribución se vuelve más pareja.

Estado civil	Todas	Con violencia
Casada	35.0%	27.6%
Soltera	26.1%	16.6%
Unión libre	18.4%	15.3%
Viuda	8.9%	11.3%
Separada	8.8%	22.4%
Divorciada	2.7%	6.8%

Tabla 2. Distribución del estado civil (ponderada por factor de expansión).




Comparación de resultados

La Tabla 3 muestra la distancia de cada grupo a un reparto perfecto, medida con cada índice.

Medida (ponderado)	Todas	Con violencia
Entropía: distancia al reparto perfecto ($1 - H_{\text{norm}}$)	13.1%	4.8%
Gini: distancia al reparto perfecto (G_{norm})	44.6%	27.7%

Categorías efectivas, 2 ^H (de 6)	4.75	5.50
Categoría mayor / categoría menor	12.8 veces	4.0 veces

Tabla 3. Distancia de cada índice a un reparto perfecto. Las categorías efectivas indican a cuántas categorías del mismo tamaño equivale la distribución.



Los dos índices coinciden en la dirección. El grupo con violencia de pareja está más cerca de un reparto parejo que la población general: la distancia de la entropía pasa de 13.1% a 4.8% y la del Gini de 44.6% a 27.7%. La magnitud que reporta cada índice es distinta. La entropía ubica al grupo con violencia casi en el reparto perfecto, a 4.8%, mientras que el Gini lo mantiene a 27.7%, una desigualdad todavía visible entre los tamaños. Los datos indican que casada es cuatro veces más grande que divorciada (27.6% frente a 6.8%), y en la población general es casi trece veces más grande (35.0% frente a 2.7%).

El mismo cambio se refleja con distinta intensidad: H_{norm} sube 0.083 (+9.5%) y G_{norm} baja 0.169 (−38%), más del doble en valor absoluto. Esto ocurre porque la entropía usa logaritmos y se aplana cerca de su máximo, de modo que cambia poco cuando el reparto ya es parejo; el Gini compara directamente los tamaños ordenados y refleja cada ajuste. El factor de expansión muestra el mismo patrón: al ponderar, el Gini cambia entre 0.019 y 0.021 y la entropía entre 0.008 y 0.011. Con y sin ponderar se llega a la misma conclusión.

Interpretación conceptual

La entropía describe qué tan repartidas están las mujeres entre los estados civiles y el Gini describe qué tan desiguales son los tamaños de esas categorías. En la ENDIREH 2021, las mujeres que reportan violencia de pareja (18,842 de las 105,753 encuestadas en la base) se distribuyen entre las seis categorías sin que ninguna supere 27.6%, y ambos índices lo reflejan: la entropía ubica la distribución a 4.8% de un reparto perfecto y el Gini a 27.7%. Esto significa que las mujeres con violencia de pareja están presentes en todos los estados civiles, y que un perfil único, como el de las casadas, cubriría poco más de una cuarta parte

de los casos reportados. Frente a la población general, separada (8.8% a 22.4%) y divorciada (2.7% a 6.8%) pesan más entre quienes reportan violencia. Para leer este resultado se debe considerar cómo se construyen los datos. La variable proviene de las respuestas de las propias encuestadas, de modo que un mayor peso de una categoría puede reflejar una violencia más frecuente, una mayor disposición a reportarla (por ejemplo, cuando la pareja ya no vive en el hogar) o ambas, y la encuesta no permite separar estas fuentes. Las mujeres que nunca tuvieron pareja (variable `nunca_tuvo_union`) no pueden reportar violencia de pareja, lo que reduce el peso de las solteras en este grupo, y el estado civil corresponde al momento de la encuesta, que puede ser posterior a la violencia reportada. Por estas razones, los índices describen cómo se reparte el estado civil entre las mujeres que **reportan** violencia y orientan la exploración de variables para análisis posteriores; interpretarlos como riesgo o causa requeriría estudios adicionales.

Tabla de Resultados

Familia de medida	Variable(s)	Valor obtenido	Interpretación en el contexto de violencia contra las mujeres
Localización (media, mediana ponderada)	- ingreso_pareja - num_hijos, - edad_primer_union	- Media ponderada de ingreso_pareja \$4,532.89, pero con mediana de \$1,500 - Media ponderada de num_hijos 2.12 - Media ponderada de edad_primer_union 9.7 años	Describen el contexto económico y familiar de las mujeres, no la violencia directamente. La mediana del ingreso de la pareja (\$1,500) muestra que la mayoría de los hogares tiene ingresos bajos, y la media lo sobreestima.
Variabilidad (CV, IQR)	- ingreso_pareja - num_hijos, - edad_primer_union	-ingreso pareja: IQR \$3000, CV 738.6% -Num_hijos: IQR 2, CV 54.3% -edad_primer_union: IQR 13años, CV 106.9%	El ingreso de la pareja es la variable más dispersa (CV 738.6 %); como tiene un sesgo muy fuerte, el IQR lo describe mejor que el CV.
Heterogeneidad (entropía, IQV)	-nom_entidad -estado_civil_desc -sufrio_violencia_pareja -apoyo_gobierno_desc -tiene_ahorros_desc]	-nom_entidad: IQV 0.976, H 4.59 estado_civil_desc: IQV 0.911, H 2.25 -sufrio_violencia_pareja: IQV 0.586, H 0.68 -apoyo_gobierno_desc: IQV 0.450, H 0.56	17.8 % reportó violencia de pareja. Cerca de 87 % no recibe apoyo del gobierno y cerca de 89 % no tiene ahorros.

		-tiene_ahorros_des c: IQV 0.391, H 0.50	
Concentración (Gini, Lorenz)	casos ponderados de violencia de pareja por entidad (32) y población de mujeres.	Casos Ponderados: G = 0.418. Población de mujeres: G = 0.406.	G = 0.418 indica concentración moderada de los casos: las 5 entidades con más casos suman el 42.7 % y las 16 con menos solo el 23 %. Como el Gini de la población es casi igual (0.406), esa concentración se explica por el tamaño de las entidades, no porque unas pocas entidades concentren la violencia
Gini vs. Entropía (síntesis)	estado_civil_des c (6 categorías), ponderado con factor_expansion , para todas las mujeres y para las que reportaron violencia de pareja	Todas: H_norm = 0.869 y G_norm = 0.446. Con violencia: H_norm = 0.952 y G_norm = 0.277	Una entropía cercana a 1 y un Gini cercano a 0 indican un reparto casi parejo entre estados civiles. En la población general, casadas y solteras suman 61% de las mujeres. Si la violencia de pareja se reportara con la misma frecuencia en todos los estados civiles, el grupo con violencia tendría esos mismos valores. El grupo con violencia tiene un reparto más parejo porque las categorías pequeñas aparecen más de lo que su tamaño haría esperar: las separadas reportan violencia con una frecuencia 2.6 veces la general y las divorciadas 2.5 veces, mientras que las solteras (0.6) y las casadas (0.8) quedan por debajo. Ningún estado civil concentra la mayoría de los casos reportados, por lo que la violencia se reporta en

			todos los perfiles. Estas diferencias pueden reflejar más violencia, mayor disposición a reportarla, o ambas.
--	--	--	---

Cuestionario

Interpretación de la curva de Lorenz y Gini

1. Interprete la curva de Lorenz obtenida para los casos de violencia por entidad: ¿la violencia reportada está concentrada en pocas entidades o distribuida de forma relativamente homogénea en el país? Apoye su respuesta con el valor del coeficiente de Gini que calculó.

La curva de Lorenz muestra que los casos de violencia de pareja no se distribuyen de manera completamente uniforme entre las entidades federativas. El coeficiente de Gini obtenido fue de 0.418, lo que indica una concentración moderada. Las cinco entidades con mayor número de casos concentran aproximadamente el 42.7 % del total.

Esta concentración puede explicarse en parte por las diferencias en el tamaño de la población de cada entidad. Por ello, el Gini de 0.418 muestra una distribución desigual de los casos absolutos, pero no permite afirmar por sí solo que exista mayor violencia en las entidades con más casos.

Limitaciones y mejoras

2. A partir de los resultados obtenidos en toda la práctica, ¿qué limitaciones detecta en los datos, en las variables disponibles o en el análisis realizado? Mencione al menos dos mejoras concretas que aplicaría en un siguiente ciclo (por ejemplo: variables adicionales a solicitar, mejor estrategia de imputación, desagregación por municipio, etc.).

Las limitaciones que vienen de la limpieza (nulos estructurales en `edad_primer_union` e `ingreso_pareja`, imputación de `num_hijos` con la mediana por estado civil y top-coding del ingreso en \$999,997) ya se describieron en la Práctica 3. A partir de esta práctica se suman otras.

En los datos, solo hay un indicador binario de violencia de pareja: no hay tipo de violencia, ámbito, frecuencia ni severidad, por lo que la comparación entre Gini y entropía no pudo hacerse sobre el tipo de violencia.

Para un siguiente ciclo aplicaríamos tres mejoras:

Primero, solicitar o integrar desde los microdatos completos de INEGI las variables de tipo y ámbito de violencia y la UPM, para calcular la heterogeneidad por tipo de violencia y los intervalos de confianza de las estimaciones por entidad.

Segundo, mejorar la imputación de num_hijos con más variables (por ejemplo, estado civil y estrato) o con un modelo, para no concentrar los valores en la mediana.

Tercero, desagregar por municipio o por tamaño de localidad para encontrar concentraciones que el nivel estatal oculta.

Uso de las medidas en decisiones posteriores

3. ¿Cómo podrían las medidas de localización, variabilidad, heterogeneidad y concentración calculadas en esta práctica orientar decisiones posteriores del proyecto, como la selección de variables para un modelo predictivo o de segmentación (por ejemplo, identificar entidades o perfiles prioritarios de atención)?

Las medidas de heterogeneidad pueden ayudar a decidir qué variables son más útiles para el modelo. Por ejemplo, ahorros (IQV 0.39) y apoyo de gobierno (0.45) tienen poca variación, así que por sí solas aportan poca información. En cambio, el estado civil presenta diferencias más marcadas: las mujeres separadas representan el 8.8 % de la población, pero concentran el 22.4 % de los casos de violencia.

También se puede observar que la variable de violencia tiene un IQV de 0.59 y que el 17.8 % de los casos corresponde a violencia. Esto indica que las categorías no están distribuidas de manera uniforme, por lo que un modelo predictivo debería considerar métricas como recall o F1 y no solo la exactitud. Para el ingreso, el CV de 738.61 % muestra una variación muy alta, por lo que sería más conveniente usar la mediana y el IQR para representarlo.

Por otro lado, las medidas de concentración ayudan a ver dónde se encuentran más casos. El Estado de México, Ciudad de México, Veracruz y Jalisco concentran una parte importante de ellos (Gini 0.418), pero la distribución es muy parecida a la de la población de mujeres (Gini 0.406).

Consideraciones éticas y comunicación

4. Al presentar públicamente un índice de concentración (Gini) por entidad federativa sobre un tema como la violencia contra las mujeres, ¿qué consideraciones éticas y de comunicación debe tener el equipo para evitar estigmatizar regiones o minimizar la gravedad del problema en las entidades con menor concentración relativa?

Al presentar el Gini por entidad, es importante no interpretarlo como si las entidades con más casos fueran necesariamente las que tienen más violencia. El Gini debe verse junto con la distribución de la población. Por ejemplo, el Estado de México concentra el 15.2 % de los casos, pero también concentra el 14.0 % de las mujeres, por lo que una parte importante de esa diferencia se explica simplemente por su tamaño de población.

Tampoco sería correcto pensar que en las entidades con menos casos el problema es menor. Baja California Sur representa solo el 0.5 % de los casos y el 0.6 % de las mujeres del país, pero eso sigue siendo más de 43 mil mujeres que reportan violencia. Por eso, al presentar porcentajes también conviene mostrar a cuántas mujeres representan.

Además, hay que dejar claro que estamos hablando de violencia reportada, no necesariamente de toda la violencia que ocurre. Que una entidad tenga menos casos puede estar relacionado con una menor disposición a denunciar, desconfianza, barreras de idioma u otras razones.

Conclusiones

Las medidas de heterogeneidad permiten identificar qué variables aportan variación y cuáles están dominadas por una categoría, lo que orienta la selección de variables. El Gini por entidad mostró una concentración moderada de casos que se explica en buena parte por la población, por lo que debe presentarse junto con tasas o prevalencias. Gini y entropía coinciden en la dirección pero difieren en magnitud: la entropía se aplana cerca de su máximo y el Gini sigue registrando diferencias de tamaño entre categorías. Todos los resultados son sobre violencia reportada y deben comunicarse sin estigmatizar entidades ni minimizar el problema en las de menor concentración.

Referencias

- Instituto Nacional de Estadística y Geografía [INEGI]. (2022). Encuesta Nacional sobre la Dinámica de las Relaciones en los Hogares (ENDIREH) 2021.
- Instituto Nacional de Estadística y Geografía [INEGI]. (2022). ENDIREH 2021. Estructura de la base de datos.
- Instituto Nacional de Estadística y Geografía [INEGI]. (2022). ENDIREH 2021. Informe operativo.
- Polars developers. (s. f.). Polars User Guide.